

Srovnání dosažené přesnosti vašeho draftu s literaturou o predikci celkového IEQ ze sensorových dat

Exekutivní shrnutí

Váš draft podle dostupného textu pracuje s reálně náročnou úlohou: z **objektivních sensorových dat** a doplňkových kontextových proměnných predikuje **celkové IEQ** na **třístupňové škále** v heterogenním školním souboru. V nejlepší konfiguraci modelu Extra Trees uvádí **macro F1 = 0,624, accuracy = 0,678** a **balanced accuracy = 0,612**; při použití pouze primárních sensorových proměnných je výkon nižší (**macro F1 = 0,537, accuracy = 0,604, balanced accuracy = 0,553**). Draft zároveň ukazuje, že přidání sekundárních/kontextových proměnných výkon zlepšuje a že některé podmnožiny dat, zejména z přednáškové místnosti, modelování komplikují. [\[filecite\]turn0file0](#)

Ve srovnání s literaturou je důležité, že **přímo srovnatelných studií je málo**. Kritické přehledy rozlišují objektivní, subjektivní-objektivní a čistě subjektivní IEQ modely a současně upozorňují, že studie se velmi liší typem vstupů, definicí cíle, váhami IEQ domén i validačním protokolem; jen menší část prací skutečně řeší **predikci celkového IEQ** z fyzikálních proměnných, nikoli pouze z dílčích subjektivních hodnocení. [\[1\]](#)

Když se omezíme na práce, které opravdu používají **senzory nebo objektivní environmentální data**, literatura často reportuje **vyšší čísla než váš draft**, ale většinou v **lehčích** nebo **méně přísných** úlohách. Utriainen a kol. klasifikovali binární vnímání IEQ ve škole a kanceláři person-specifickými SVM modely a reportovali přibližně **84% přesnost** pro IEQ, přičemž u učitelů pro „overall IEQ perception“ dosáhli až **0,91 accuracy**; šlo však o **binární, person-specifické** modely s oknem dvou hodin a validací typu leave-one-self-report-out. [\[2\]](#) Alam a kol. v norské škole predikovali nikoli individuální třídy spokojenosti, ale **agregovanou míru nespokojených** s celkovým IEQ a u Random Forest uvádějí až **$R^2 = 0,91$** ; jejich cíl je ale hladší a statisticky „snazší“ než individuální třídní klasifikace. [\[3\]](#) Mujan a kol. zase vyhodnocovali **kompozitní IEQ index** z low-cost monitoringu a uvádějí **MAE < 3 %** vůči průměrným výsledkům dotazníků, což je užitečné pro benchmarking indexů, ale není to srovnatelná klasifikační úloha. [\[4\]](#)

Naopak studie s nejvyššími reportovanými čísly často používají **subjektivní vstupy**, nikoli syrová sensorová data. Tang a kol. predikovali celkovou spokojenost z **tepelné, akustické, vizuální a IAQ spokojenosti**, nikoli z CO₂, teploty, RH a dalších fyzikálních proměnných; na interní validaci dosáhli až **RMSE = 0,85** u XGBoost a při externím testu byl nejlepší model WHM s **RMSE = 1,05**. [\[5\]](#) Tsang a kol. predikovali **overall IEQ acceptance** z kombinace **sensation + acceptance** pro jednotlivé domény a u Random Forest se SMOTE reportovali na externím testovacím souboru **accuracy = 0,98** a **F1 = 0,97**, ale opět nešlo o predikci z fyzikálních senzorů. [\[6\]](#)

Hlavní závěr tedy není, že by váš draft „zaostával“, ale že stojí v **metodologicky přísnější části literatury**: používá objektivní vstupy, pracuje s vícetřídním cílem, s heterogenním školním souborem a bez pomoci subjektivních subdoménových hlasů. Právě to velmi pravděpodobně vysvětluje, proč jsou dosažené hodnoty „jen“ střední, ale současně **věrohodné a prakticky cenné**. Ve své kategorii je váš výsledek spíše **konzervativní, realistický a publikačně obhajitelný** než slabý. [\[7\]](#)

Co uvádí váš draft

Z dostupného textu draftu vyplývá, že analýza vychází z dat sesbíraných ve **3 školách / 11 učebnách** během **5 měřicích kampaní** v období **říjen 2023 až duben 2024**, zahrnuje **321 studentů** a celkem **6 834 hodnocení**. Jako primární objektivní proměnné jsou používány alespoň **teplota vzduchu, relativní vlhkost, CO₂, osvětlení a hluk**, vedle nich i sekundární proměnné související s kontextem a respondentem; v dostupném textu však není pro všechny proměnné ani pro senzorický sampling jednoznačně a konzistentně vypsána plná technická specifikace, takže je fér část detailů označit jako **nespecifikované v dostupném draftu**. [\[7\]](#)

Draft srovnává více algoritmů, konkrétně **logistickou regresi, MLP/ANN, Random Forest, Gradient Boosting a Extra Trees**. Chybějící hodnoty jsou podle dostupného textu imputovány **mediánem v rámci třídy/skupiny**, modely jsou laděny a vyhodnocovány pomocí **5-fold cross-validation**. Zvlášť jsou porovnávány varianty s **primárními** a s **primárními + sekundárními** proměnnými a je provedena i dodatečná analýza přenositelnosti mezi školními segmenty. [\[7\]](#)

Pokud jde o výkon, nejlepší varianta v draftu je podle dostupného textu **Extra Trees** s primárními a sekundárními proměnnými, která dosahuje **macro F1 = 0,624, accuracy = 0,678 a balanced accuracy = 0,612**. V čisté senzorické variantě s primárními proměnnými je nejlepší rovněž Extra Trees, ale pouze s **macro F1 = 0,537, accuracy = 0,604 a balanced accuracy = 0,553**. To je velmi důležité zjištění: samotné senzory nesou část informace o celkovém IEQ, ale **kontext a individualita respondentů** zjevně přidávají významný informační zisk. [\[7\]](#)

Draft dále naznačuje několik limitů, které jsou v literatuře opakovaně přítomné: obtížnější separaci střední a vyšší třídy spokojenosti, citlivost na nevyváženost tříd a na heterogenitu prostoru a skutečnost, že určitá dílčí prostředí, zejména **přednášková místnost**, vedou k horším výsledkům a byly v některých doplňkových analýzách problematické. Numerické intervaly nejistoty, konfidenční intervaly či bootstrapové rozptyly ale draft ve zpřístupněném textu zjevně neuvádí, takže oblast **nejistot** je zatím spíše nedorozpracovaná. [\[7\]](#)

Jak si draft stojí vůči literatuře

Nejpříměji srovnatelná je s vaším draftem práce Utriainena a kol., protože používá skutečná **environmentální senzorová data** ve škole a kanceláři a cílí na vnímané IEQ. Tato studie měřila **teplotu, RH, tlak a CO₂** v intervalu **60 s** během **3,5 až 7 měsíců**, používala

person-specifické SVM modely a validaci **leave-one-self-report-out**. Reportovaná přesnost pro „IEQ“ je kolem **84 %**, pro učitele dokonce **0,91 accuracy** u „overall IEQ perception“. Jenže jde o **binární klasifikaci**, navíc person-specifickou, takže je metodicky snazší než váš vícetřídní, pooled model. Přesně tento rozdíl je pro interpretaci výsledků zásadní. [2]

Práce Alam a kol. je školně-contextová a senzorově bohatší: kombinuje **senzorová data, venkovní počasí a stavební parametry** ze **3 tříd a 1 437 studentských odpovědí** napříč sezónami. Nejlepší Random Forest zde dosahuje až **$R^2 = 0,91$** pro **PDIEQ%**, tedy procento nespokojených s celkovým IEQ. To je výborný výsledek, ale míří na **agregovanou regresní veličinu**, nikoli na individuální třídní klasifikaci. Jinými slovy: tato práce ukazuje, že ze senzorů lze predikovat „kolektivní stav“ třídy velmi dobře, ale nepřímo podporuje i to, že individuální a vícetřídní úlohy, jako ve vašem draftu, budou přirozeně těžší. [3]

Mujan a kol. i Yang a Mak reprezentují jiný proud literatury: místo přímé klasifikace individuální spokojenosti budují **kompozitní IEQ indexy**. Mujan a kol. vyvinuli low-cost platformu ENVIRA a pro tři field studies s **125 účastníky** uvádějí **MAE < 3 %** mezi průměrnými výsledky dotazníků a celkovým IEQ indexem. Yang a Mak navrhli pro **8 univerzitních učeben** v Hongkongu model FCE/AHP s objektivními vstupy jako **operativní teplota, CO₂, osvětlení a hluk** a s **224 respondenty**; publikují váhy a predikční formule, ale nikoli moderní klasifikační metriky typu macro F1 nebo externí test accuracy. Tyto práce jsou pro váš text důležité jako důkaz, že objektivní kompozitní modely existují, ale jejich výstupy nejsou přímo zaměnitelné s vaším výsledkem. [8]

Weng a kol. jsou blíže školnímu provozu a kombinují **dlouhodobý monitoring a point-to-point dotazníky** ve třech univerzitních budovách v Číně. Měřili mimo jiné **teplotu, RH, CO₂, PM2.5 a hluk po 5 minutách** a na základě **399 dotazníků** sestavili subjektivně-objektivní IEQ model. Pro regresi celkové spokojenosti na subspokojenosti uvádějí **$R^2 = 0,483$** a z odhadnutých vah odvozují IEQoverall. To je relevantní jako školní benchmark pro propojení objektivních a subjektivních dat, ale studii chybí křížová validace i výkonnostní metriky srovnatelné s vaší klasifikací. [9]

Tang a kol. a Tsang a kol. pak představují „silné“, ale jen **nepřímo srovnatelné** benchmarky. Tang a kol. používají místo fyzikálních veličin čtyři subjektivní doménové spokojenosti a dosahují v interní validaci až **RMSE = 0,85** a při externím testu nejlepšího **RMSE = 1,05** u WHM modelu. Tsang a kol. predikují overall IEQ acceptance z kombinace sensation a acceptance jednotlivých domén a u RF+SMOTE dosahují na externím testovacím souboru **accuracy = 0,98** a **F1 = 0,97**. Tyto výsledky jsou vysoké, ale vypovídají spíše o tom, že celkové IEQ lze dobře odvodit ze **subjektivních dílčích soudů**, nikoli o tom, že raw senzory samy o sobě postačí stejně dobře. [10]

Právě zde má váš draft silnou publikační pozici: ukazuje, jak daleko lze dojít bez „úniku informace“ přes subjektivní subdoménové hlasy. To znamená, že výsledné **macro F1 0,624** a **accuracy 0,678** je vhodné v textu rámovat nikoli jako nízký výkon, ale jako **realistický benchmark pro náročnou, individual-level, multiclass, sensor-only úlohu**. Tento framing je podle dostupné literatury věcně udržitelný. [11]

Kapitola vhodná k vložení do článku

Predikce celkového indoor environmental quality z objektivních senzorových dat představuje v současné literatuře stále relativně úzký segment výzkumu. Přehledové práce ukazují, že většina IEQ modelů je založena buď na subjektivních hodnoceních jednotlivých domén, nebo na kompozitních indexech odvozených z vážených fyzikálních ukazatelů; přímé modelování celkového IEQ z raw senzorových dat bez využití subjektivních subdoménových vstupů je podstatně méně časté. Současně se jednotlivé studie významně liší způsobem sběru dat, definicí cílové proměnné, použitými validačními protokoly i reportovanými metrikami, což komplikuje přímé porovnání dosažené přesnosti. [1]

V tomto kontextu je náš model metodologicky přísný. Pracuje s daty ze tří škol a jedenácti učeben, zahrnuje 321 respondentů a 6 834 hodnocení a predikuje celkové IEQ na třístupňové škále z primárních senzorových proměnných a doplňkových sekundárních proměnných. Nejlepšího výsledku dosáhl model Extra Trees, který při použití primárních i sekundárních proměnných dosáhl macro F1 = 0,624, accuracy = 0,678 a balanced accuracy = 0,612; při použití pouze primárních proměnných byly výsledky nižší (macro F1 = 0,537; accuracy = 0,604; balanced accuracy = 0,553). Tyto výsledky dokládají, že samotná fyzikální data nesou o celkovém IEQ významnou, avšak ne úplnou informaci a že kontextové charakteristiky prostředí a respondentů mají pro interpretaci celkového IEQ zásadní význam. [filecite]turn0file0[

Přímo srovnatelných prací se senzorickými vstupy je málo. Utriainen a kol. použili person-specifické SVM modely nad teplotou, relativní vlhkostí, tlakem a CO₂, měřeními po 60 s v reálném školním a kancelářském provozu, a pro binární percepci IEQ reportovali přibližně 84% přesnost; u učitelů dosáhla přesnost pro overall IEQ perception až 0,91. Významnou metodickou odlišností je však person-specifické učení a binární formulace úlohy, která je snazší než vícetřídní pooled klasifikace na úrovni jednotlivých odpovědí. [2]

Podobně Alam a kol. v norské školní budově kombinovali senzorická data, meteorologické údaje a stavební parametry a pomocí Random Forest dosáhli až $R^2 = 0,91$ při predikci podílu nespokojených s celkovým IEQ. Přesto ani tento výsledek nelze interpretovat jako přímý ekvivalent našim hodnotám, protože zde byla cílovou proměnnou agregovaná míra nespokojenosti na úrovni prostoru, nikoli individuální třídní hodnocení. Agregovaný cíl má nižší šum a bývá modelovatelný lépe než individuální odpovědi. [3]

Další studie, například Mujan a kol. nebo Yang a Mak, ukazují, že z objektivních environmentálních veličin lze konstruovat kompozitní IEQ indexy. Mujan a kol. uvádějí MAE nižší než 3 % mezi dotazníkovým hodnocením a výsledným IEQ indexem založeným na low-cost monitoringu, zatímco Yang a Mak navrhli ve vysokoškolských učebnách model FCE/AHP s objektivními vstupy (operativní teplota, CO₂, osvětlení, hluk) a s predikčními rovnicemi pro vazbu mezi dílčími environmentálními parametry a IEQ. Tyto přístupy jsou důležité jako srovnávací rámec, ale spíše validují konstrukci indexu než schopnost klasifikovat individuální celkové IEQ v náročném vícetřídním nastavení. [8]

Naopak nejvyšší přesnosti v literatuře jsou zpravidla dosaženy v úlohách, které nejsou senzoricky ekvivalentní našemu nastavení. Tang a kol. predikovali celkovou spokojenost z již subjektivně hodnocených domén IEQ a reportovali RMSE až 0,85 v interní validaci a 1,05 v externím testu. Tsang a kol. zase predikovali celkovou IEQ akceptaci ze sensation a acceptance jednotlivých domén a na externím testu dosáhli accuracy 0,98 a F1 0,97 při použití Random Forest se SMOTE. Tyto výsledky potvrzují, že celkové IEQ je silně determinováno subjektivním hodnocením jednotlivých domén, ale současně ukazují, že přímé srovnání s modelem založeným na raw senzorech by bylo metodicky zavádějící. [10]

Z komparativního hlediska tak lze uzavřít, že naše dosažená přesnost je nižší než ve studiích s binárními cíli, person-specifickými modely nebo subjektivními vstupy, avšak odpovídá vyšší obtížnosti řešené úlohy. Praktickým přínosem našeho přístupu je právě to, že odhaduje celkové IEQ z objektivních veličin, které mohou být měřeny průběžně bez nutnosti trvalého dotazování uživatelů. Pro další zlepšení přesnosti se jako nejperspektivnější jeví rozšíření spektra měřených proměnných o PM a VOC, explicitní modelování obsazenosti a časových zpoždění, hierarchické nebo leave-one-room-out validační schéma a důsledné reportování nejistot, například pomocí bootstrapových intervalů nebo opakované vnější validace. Toto směřování je v souladu s novější literaturou, která ukazuje přínos širších feature setů, robustnější validace a interpretovatelných modelů včetně SHAP analýzy. [12]

Srovnávací tabulka

Studie	Míra srovnatelnosti s vaším draftem	Dataseta	Definice cíle	Features a preprocessing	Modely	Validace	Reportovaný výkon	Nejistoty / limity	Zdroj
Váš draft	Přímá reference	3 školy, 11 učeben, 321 studentů, 6 834 hodnocení, 5 kampaní; senzor	Celkové IEQ na 3 třídách spokojenosti	Primární senzorové; proměnné; sekundární/contextové proměnné; imputace mediánem	Logistické Regrese, MLP / ANN, RF, GB, Extra Trees	5-fold CV; doplněná přenosová analýza mezi segmenty	Nejlépe ET s primárními + sekundárními: macro F1 0,624; accuracy 0,678; balanced accuracy 0,612; primární-only ET: 0,537 /	Confusion matrix a vyšší třídou; část detailů a intervaly nejistoty nejsou	[12]

Stu die	Míra srovn ateln osti s vaším drafte m	Datas et a senzo ry	Definic e cíle	Features a preproce ssing	Mod ely	Valid ace	Reportova ný výkon	Nejist oty / limity	Zdroj
		zahrn ují teplot u, RH, CO ₂ , osvětł ení a hluk; sampl ing v dostu pném textu není jedno značn ě specif ikován					0,604 / 0,553	u v dostu pném draftu vypsá ny	
Utri ain en et al., 202 0	Vysok á, ale binár ní a perso n- specif ická úloha	Škola + kance lář; 15 office worke rs a 4 teach ers pro hlavní IEQ analýz u; T, RH, tlak, CO ₂ ;	Binární „bad/O K“ pro IEQ, air freshne ss, thermal comfort a „any IEQ proble m“	tsfresh, >300 feature z 2h okna před self- reportem ; person- specific modely	SVM	Leave -one- self- repor t-out	Paper-level IEQ ≈ 84 % accuracy ; u teacher overall IEQ až 0,91 accuracy	Malý počet subje ktů, perso n- specif ic učení , binár ní cíl	[2]

Stu die	Míra srovn ateln osti s vaším drafte m	Datas et a senzo ry	Definic e cíle	Features a preproce ssing	Mod ely	Valid ace	Reportova ný výkon	Nejist oty / limits	Zdroj
		sample interval 60 s ; délka 3,5–7 měsíc ů							
Muj an et al., 202 1	Střed ní; komp ozitní index spíše než klasifi kace	3 field studie s; 125 occup antů, 2 open office s + 1 educa tional buildi ng; low- cost platfo rm ENVIR A; kontin uální monit oring releva ntních IEQ param	Celkový IEQ index z vážených domén	Váhy IEQ domén odvozeny regresní analýzou dotazníků ; building- type- specific weighting	Regr esně váže ný inde x / scori ng sche me	Porov nání index u a prům ěrných surve y výsle dků ve 3 studiích	MAE < 3 % mezi průměrnými výsledky survey a overall IEQ indexem	Není to indivi dual- level klasifi kace; samp ling rate v abstr aktu neuve den	[4]

Stu die	Míra srovn ateln osti s vaším drafte m	Datas et a senzo ry	Definic e cíle	Features a preproce ssing	Mod ely	Valid ace	Reportova ný výkon	Nejist oty / limits	Zdroj
		etrů							
Yan g & Ma k, 202 1	Střed ní; objek tivní classr oom mode l, ale bez klasifi kační ch metri k	8 univer zitních učebe n v Hongk ongu; 224 respo ndent ů; operat ivní teplot a, CO ₂ , osvětł ení, A- weight ed hluk	FCE/AH P overall IEQ model + predikč ní formule mezi environ mentál ními faktory a IEQ	Vícevrstv ý FCE model, AHP váhy; predikční formule pro subdomé ny	FCE + AHP	Evalu ace na surve y + meas urem ent datas etu	Publikován y váhy a formule; explicitní accuracy/ macro F1/RMSE pro overall model neuveden y v dostupné m zdroji	Autoři sami uvádě jí nejjist oty predi kčních h formu lí a neřeš ené intera kce faktor ů	[13]
Tan get al., 202 2	Nepří má; cíl je obdob ný, vstup y nejso u senzo rové	Datas et I: 56 subjek tů, 43 kontro lovaný ch IEQ podmí nek, 1 584 valid respo	Overall satisfac tion na škále 1– 10	Vstupy = subjektiv ní thermal, acoustic, visual a IAQ satisfacti on	Line ar, WG M, WH M, RF, XGB oost	10- fold CV + exter ní valida ce na druhé m datas etu	CV RMSE: Linear 1,02 , WGM 0,93 , WHM 0,88 , RF 0,87 , XGBoost 0,85 ; externě nejlepší WHM 1,05 RMSE	Vyšší čísla jsou dosaž ena se subje ktivní mi domé nový mi vstup	[5]

Stu die	Míra srovn ateln osti s vaším drafte m	Datas et a senzo ry	Definic e cíle	Features a preproce ssing	Mod ely	Valid ace	Reportova ný výkon	Nejist oty / limity	Zdroj
		nse; Datas et II: 1 526 online respo nses z různýc h budov						y; SD RMSE jen grafic ky	
We ng et al., 202 3	Střed ní; školní objek tivně- subje ktivní IEQ mode l	3 univer zitní budov y (green / retrofi tted / conve ntiona l); 399 point- to- point dotaz níků; T, RH, CO ₂ , PM2.5 , SPL každý ch 5 min	Overall satisfac tion + objectiv e- subjecti ve IEQove rall	Complian ce rates, Pearson korelace, multiple regressio n mezi overall satisfacti on a sub- satisfacti on	Regr esní mod el + váže ný IEQ inde x	Bez CV; klasic ká regre sní evalu ace	Multiple regression pro overall satisfactio n: R² = 0,483 ; váhy pro index: T 0,36 , AQ 0,14 , V 0,19 , AC 0,31	Bez exter ní valida ce; spíše konst rukce index u než predi kční benc hmar king	[9]
Tsa ng	Nepří má;	Vývojo vý	Binary overall	Vstupy = sensation	LR, RF,	80/20 split	RF + SMOTE na	Cíl i vstup	[6]

Stu die	Míra srovn ateln osti s vaším drafte m	Datas et a senzo ry	Definic e cíle	Features a preproce ssing	Mod ely	Valid ace	Reportova ný výkon	Nejist oty / limits	Zdroj
et al., 202 3	velmi vysok á výkon nost, ale bez raw senzo rů	datas et: 435 IEQ rating s (office , elderl y center s, reside ntial); extern í test: 40 valid hospit al respo nses	IEQ accept ance	a acceptan ce 4 IEQ domén; řešení imbalanc e přes SMOTE, class weights, threshold tuning	SVM , GB, DT, NB aj.	na vývoj ových datec h + exter ní testo vací datas et	testovacím datasetu: accuracy 0,98; F1 0,97; LR s class weights: 0,95 / 0,83	y jsou subje ktivní; vysok á přesn ost není přímo přeno siteln á na senzo r-only úlohu	
Cro ffi et al., 202 5	Střed ní až vyšší; 3 třídy, ale single -case study	Post- occup ancy data z jedné high- rise mixed -use budov y v Adelai de; monit	Třídy Dissati sfied / Neutral / Satisfie d pro indoor environ ment satisfac tion	Balancin g přes resampli ng a cost- sensitive learning	Ran dom Fore st, Neur al Net work	Cross - valida tion, class - speci fic metri cs	Cross- validation score > 0,80; přesná hodnota v dostupnýc h zdrojích nespecifik ována	Single case study ; zatím omez ená gener alizac e	[14]

Stu die	Míra srovn ateln osti s vaším drafte m	Datas et a senzo ry	Definic e cíle	Features a preproce ssing	Mod ely	Valid ace	Reportova ný výkon	Nejist oty / limits	Zdroj
		oring indoor enviro nment al factor s pomo cí data logger ů + survey							
Ala m et al., 202 5	Vysok á pro školní konte xt, ale agreg ovaný cíl	3 classr oomy v norsk é škole, více sezón, 1 437 stude ntskýc h odpov ědí; senso r- based meas ureme nts + weath er +	PDIEQ % a další dissatis faction rates	Statistic ká preselekc e vstupů; SHAP interpreta ce	RF, MLR , DT	Evalua ční postu p v abstr aktu neupř esně n; mode ly byly vyvin uty a porov nává ny	RF: až R² = 0,91 pro overall IEQ dissatisfac tion (PDIEQ%)	Agreg ovaný cíl na úrovn i prost oru; nikoli indivi dual- level třídní klasifi kace	[3]

Studie	Míra srovnatelnosti s vaším draftem	Dataseta	Definice cíle	Features a preprocessing	Modely	Validace	Reportovaný výkon	Nejistoty / limity	Zdroj
		building parameters							

Vizualizace

Následující graf srovnává pouze ty studie, které reportují **klasifikační accuracy**. Není to „fair“ apples-to-apples benchmark; záměrně ukazuje, jak prudce roste vykazovaná přesnost, když se úloha zjednoduší z vícetřídní pooled klasifikace na binární, person-specifickou nebo subjektivně vstupní formulaci. [\[15\]](#)

```
xychart-beta
    title "Vybrané klasifikační accuracy v literatuře"
    x-axis ["Váš draft ET 3 třídy", "Utriainen 2020 IEQ", "Utriainen 2020 učitelé overall IEQ", "Tsang 2023 RF+SMOTE"]
    y-axis "Accuracy" 0 --> 1.0
    bar [0.678, 0.84, 0.91, 0.98]
```

Typický pipeline, který se napříč literaturou opakuje, vypadá následovně. Váš draft se do něj dobře vejde, ale ve srovnání s částí literatury je přísnější hlavně ve volbě cíle a v tom, že nevyužívá subjektivní subdoménové hlasy jako vstupní proměnné. [\[16\]](#)

```
flowchart TD
    A[Sběr dat] --> B[Kontrola kvality dat]
    B --> C[Agregace v čase a synchronizace]
    C --> D[Feature engineering]
    D --> E[Modelování]
    E --> F[Validace]
    F --> G[Interpretace modelu]
    G --> H[Doporučení pro provoz budovy]

    A1[Tepłota, RH, CO2, PM, VOC, světlo, hluk, obsazenost] --> A
    A2[Kontext: typ místnosti, škola, respondent, počasí] --> A
    A3[Volitelně: subjektivní subdoménová hodnocení] --> A

    D1[Statistiky oken, lagy, rolling features, imputace] --> D
    E1[LR / RF / GB / ET / XGBoost / NN / SVM] --> E
    F1[K-fold CV] --> F
    F2[Leave-one-room-out] --> F
```

F3[Externí test] --> F
G1[Feature importance / SHAP] --> G

Otevřené otázky a limity

Nejšířejí platí, že literatura o **predikci celkového IEQ z raw senzorů** je pořád metodicky roztržštěná. Přehledové práce výslovně upozorňují na rozdíly v typu modelů, vstupních datech, vahách IEQ domén i v kvalitě validace, což omezuje jednoduché porovnání jediné metriky mezi studiemi. [1]

U několika primárních studií nebyl v otevřeně dostupném zdroji dohledatelný celý soubor technických detailů, zejména přesný sampling, plná sada feature engineering kroků nebo intervaly nejistoty. V tabulce jsou proto tyto položky transparentně označeny jako **nespecifikované v dostupném zdroji** a nebyly domýšleny. [17]

Pro finální verzi článku bych doporučil formálně doplnit tři věci. Zaprvé explicitně rozepsat technický senzorický protokol a sampling. Zadruhé doplnit výsledky o **confusion matrix**, případně class-wise precision/recall/F1 a intervaly nejistoty. Zatřetí, pokud to data dovolí, přidat přísnější **leave-one-room-out** nebo **leave-one-school-out** validaci; právě ta by váš článek posunula z dobře zvládnuté modelové studie k silnějšímu příspěvku o generalizaci napříč učebnami a školami. Tato doporučení jsou v souladu jak s limity vašeho draftu, tak s tím, co v literatuře odlišuje silnější a slabší IEQ modely. [18]

[1] [11] [18] <https://www.sciencedirect.com/science/article/pii/S0378778822002043>

<https://www.sciencedirect.com/science/article/pii/S0378778822002043>

[2] [15]

https://www.researchgate.net/publication/339821920_Assessment_of_perceived_indoor_environmental_quality_stress_and_productivity_based_on_environmental_sensor_data_and_personality_categorization/fulltext/5e67aafd299bf1744f70cba4/Assessment-of-perceived-indoor-environmental-quality-stress-and-productivity-based-on-environmental-sensor-data-and-personality-categorization.pdf

https://www.researchgate.net/publication/339821920_Assessment_of_perceived_indoor_environmental_quality_stress_and_productivity_based_on_environmental_sensor_data_and_personality_categorization/fulltext/5e67aafd299bf1744f70cba4/Assessment-of-perceived-indoor-environmental-quality-stress-and-productivity-based-on-environmental-sensor-data-and-personality-categorization.pdf

[3] [7] [12] [16] <https://www.sciencedirect.com/science/article/pii/S0360132325006237>

<https://www.sciencedirect.com/science/article/pii/S0360132325006237>

[4] [8] <https://www.sciencedirect.com/science/article/pii/S0959652621020643>

<https://www.sciencedirect.com/science/article/pii/S0959652621020643>

[5] [10] https://www.researchgate.net/profile/Hao-Tang-96/publication/358010338_Assessing_the_perception_of_overall_indoor_environmental_quality_Model_validation_and_interpretation/links/651528d5f91aee386e74417c/Assessing-the-perception-of-overall-indoor-environmental-quality-Model-validation-and-interpretation.pdf

https://www.researchgate.net/profile/Hao-Tang-96/publication/358010338_Assessing_the_perception_of_overall_indoor_environmental_quality_Model_validation_and_interpretation/links/651528d5f91aee386e74417c/Assessing-the-perception-of-overall-indoor-environmental-quality-Model-validation-and-interpretation.pdf

[6] <https://ira.lib.polyu.edu.hk/bitstream/10397/108278/1/sustainability-15-11094.pdf>

<https://ira.lib.polyu.edu.hk/bitstream/10397/108278/1/sustainability-15-11094.pdf>

[9]

https://www.researchgate.net/publication/366694447_Field_Measurements_and_Analysis_of_Indoor_Environment_Occupant_Satisfaction_and_Sick_Building_Syndrome_in_University_Buildings_in_Hot_Summer_and_Cold_Winter_Regions_in_China/fulltext/63b34b0ea03100368a498953/Field-Measurements-and-Analysis-of-Indoor-Environment-Occupant-Satisfaction-and-Sick-Building-Syndrome-in-University-Buildings-in-Hot-Summer-and-Cold-Winter-Regions-in-China.pdf

https://www.researchgate.net/publication/366694447_Field_Measurements_and_Analysis_of_Indoor_Environment_Occupant_Satisfaction_and_Sick_Building_Syndrome_in_University_Buildings_in_Hot_Summer_and_Cold_Winter_Regions_in_China/fulltext/63b34b0ea03100368a498953/Field-Measurements-and-Analysis-of-Indoor-Environment-Occupant-Satisfaction-and-Sick-Building-Syndrome-in-University-Buildings-in-Hot-Summer-and-Cold-Winter-Regions-in-China.pdf

[13]

https://ira.lib.polyu.edu.hk/bitstream/10397/102832/1/Yang_Relationships_Indoor_Environmental.pdf

https://ira.lib.polyu.edu.hk/bitstream/10397/102832/1/Yang_Relationships_Indoor_Environmental.pdf

[14] <https://digital.library.adelaide.edu.au/items/d405af68-5f32-4416-8390-c305d6127d53>

<https://digital.library.adelaide.edu.au/items/d405af68-5f32-4416-8390-c305d6127d53>

[17] <https://www.emerald.com/sasbe/article-pdf/doi/10.1108/SASBE-03-2025-0161/10423525/sasbe-03-2025-0161en.pdf>

<https://www.emerald.com/sasbe/article-pdf/doi/10.1108/SASBE-03-2025-0161/10423525/sasbe-03-2025-0161en.pdf>